Architecture

1 Arquitetura do FACIN_IA_D_P_N_1

1.1 🧬 Arquitetura Geral

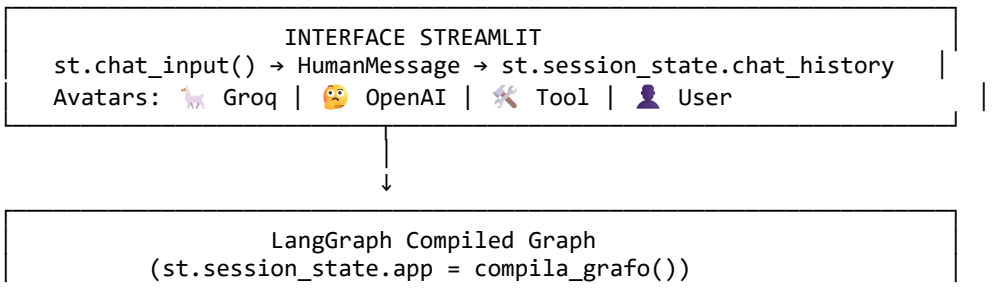

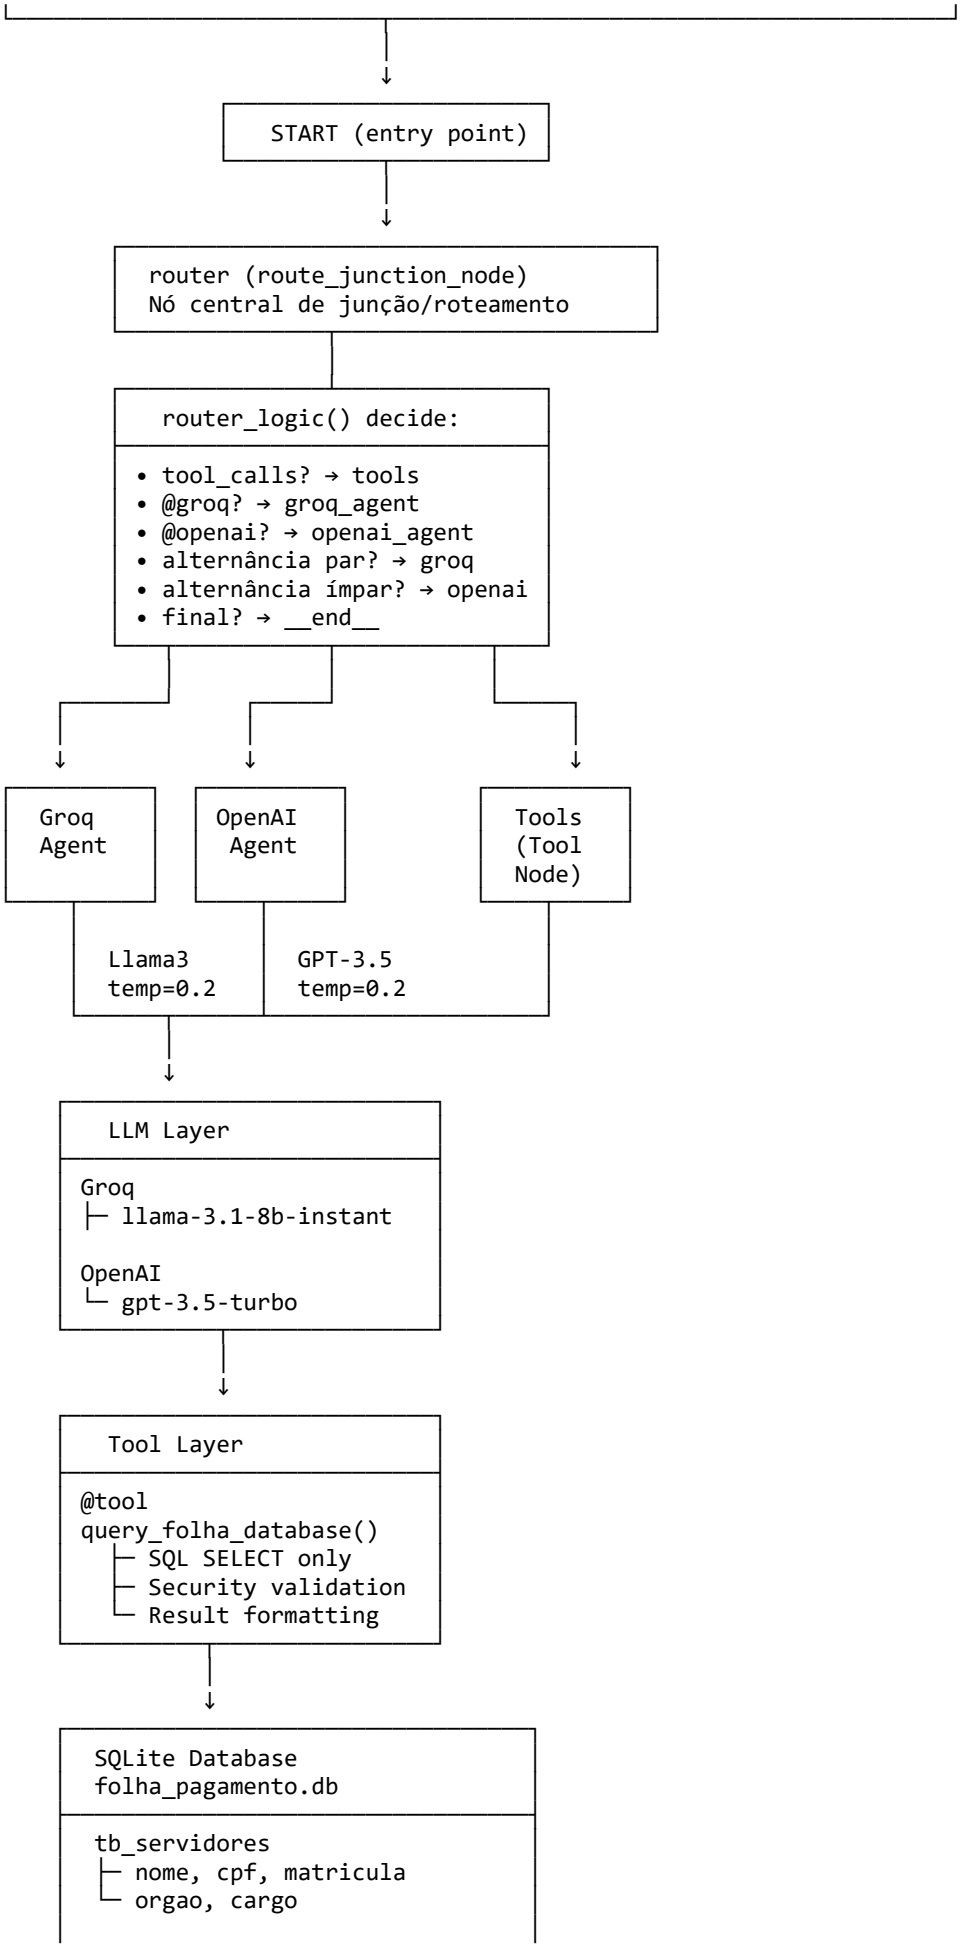
START (entry point)
router (route_junction_node)
Nó central de junção/roteamento
router_logic() decide:
• tool_calls? → tools
• @groq? → groq_agent
• @openai? → openai_agent
• alternância par? → groq
• alternância ímpar? → openai
• final? → __end__
Groq Agent
OpenAI Agent
Tools (Tool Node)
Llama3 temp=0.2
GPT-3.5 temp=0.2
LLM Layer
Groq
├─ llama-3.1-8b-instant
OpenAI
└─ gpt-3.5-turbo
Tool Layer
@tool
query_folha_database()
├─ SQL SELECT only
├─ Security validation
└─ Result formatting
SQLite Database
folha_pagamento.db
tb_servidores
├─ nome, cpf, matricula
└─ orgao, cargo

```
  tb_folha_pagamento
  ├─ matricula, competencia
  └─ vencimentos, descontos,
     liquido
```

```
AgenticOps (Opcional)
- Event Logging
- Performance Monitoring
- Error Tracking
```

1.2 🤖 Sistema Multi-Agentes

1.2.1 Componentes Principais

1.2.1.1 1. Agent Router (router_logic)

```
Função: Lógica de roteamento condicional
Entrada: AgentState com histórico de mensagens
Saída: Nome do próximo nó ("groq_agent", "openai_agent", "tools", "__end__")
```

Decisões de Roteamento:

```
1. Se AIMessage.tool_calls existe → "tools"
2. Se AIMessage sem tool_calls → "__end__"
3. Se HumanMessage com "@groq" → "groq_agent"
4. Se HumanMessage com "@openai" → "openai_agent"
5. Se ToolMessage ou alternância:
   - ai_count % 2 == 0 → "groq_agent"
   - ai_count % 2 != 0 → "openai_agent"
```

1.2.1.2 2. Groq Agent (groq_agent_node)

```
Modelo: llama-3.1-8b-instant
Temperatura: 0.2
Função: Consultar banco de dados da Folha de Pagamento
Ferramentas:
  - query_folha_database()
Saída: {"messages": [AIMessage]}
```

Prompt do Sistema: > Você é um assistente de Folha de Pagamento experiente chamado Groq (modelo Llama3). > Use a ferramenta ‘query_folha_database’ fornecendo uma consulta SQL SELECT válida.

1.2.1.3 3. OpenAI Agent (openai_agent_node)

```
Modelo: gpt-3.5-turbo
Temperatura: 0.2
Função: Consultar banco de dados da Folha de Pagamento
Ferramentas:
  - query_folha_database()
Saída: {"messages": [AIMessage]}
```

Prompt do Sistema: > Você é um assistente de Folha de Pagamento experiente chamado OpenAI (modelo GPT). > Utilize a ferramenta ‘query_folha_database’ para executar consultas SQL SELECT.

1.2.1.4 4. Router Junction Node (route_junction_node)

```
Função: Nó de junção/hub central sem modificação de estado
Entrada: AgentState
Saída: {} (empty dict)
Propósito: Ponto explícito de roteamento no grafo
```

1.2.1.5 5. Tool Executor (ToolNode)

```
Função: Execução de ferramentas registradas
Ferramentas:
  - query_folha_database(): Consultas SQL SELECT
Saída: ToolMessage com resultado
```

1.3 📊 Estado da Conversa (AgentState)

```python
class AgentState(TypedDict):
    messages: Annotated[List[BaseMessage], operator.add]
```

Campo: - `messages`: Lista de BaseMessage com operador de agregação (+)

Tipos de Mensagem:

1. **HumanMessage**
   - Origem: Usuário via st.chat_input()
   - Contém: Pergunta/solicitação do usuário
2. **AIMessage**
   - Origem: Groq Agent ou OpenAI Agent
   - Contém:
     - `content`: Resposta textual
     - `tool_calls`: Lista de chamadas de ferramentas (opcional)
     - `name`: Nome do agente (opcional)
3. **ToolMessage**
   - Origem: ToolNode após execução de ferramenta
   - Contém:
     - `content`: Resultado da ferramenta
     - `tool_call_id`: ID da chamada
     - `name`: Nome da ferramenta

Operação de Agregação:

```python
# operator.add permite concatenação automática
state1 = {"messages": [msg1, msg2]}
state2 = {"messages": [msg3]}
# Resultado: {"messages": [msg1, msg2, msg3]}
```

1.4 🔄 Fluxo de Execução

1.4.1 1. Entrada do Usuário

```
Usuário digita pergunta → st.chat_input() → HumanMessage
                                                ↓
                            Adicionado a st.session_state.chat_history
                                                ↓
                                          st.rerun()
```

1.4.2 2. Inicialização do Grafo

```
Verifica st.session_state.app existe?
  │
  ├─ Não → compila_grafo() → Salva em st.session_state.app
  │
  └─ Sim → Usa grafo existente
```

1.4.3 3. Processamento

```
┌──────────────────────────────────────┐
│ Invoca grafo com estado atual        │
▼                                      │
START                                  │
  ↓                                    │
router (route_junction_node)           │
  ↓                                    │
router_logic() decide:                 │  LOOP
  ├─ tool_calls? → tools               │  ATÉ
  ├─ @groq? → groq_agent               │  __end__
  ├─ @openai? → openai_agent           │
  ├─ alternância par? → groq_agent     │
  ├─ alternância ímpar? → openai       │
  └─ final? → __end__                  │
                                       │
Agente executa:                        │
  1. Cria ChatPromptTemplate           │
  2. Invoca LLM (Groq/OpenAI)          │
  3. Retorna AIMessage                 │
       │                               │
       └───────────────────────────────┘
```

1.4.4 4. Uso de Ferramentas

```
AIMessage.tool_calls existe?
  ↓
Sim → ToolNode executa:
       1. Valida SQL (apenas SELECT)
       2. Conecta ao SQLite
       3. Executa query
       4. Formata resultado (tabela)
       5. Retorna ToolMessage
  ↓
Router recebe ToolMessage → Roteia para agente novamente
  ↓
Agente processa resultado → AIMessage com resposta final
```

1.4.5 5. Resposta Final

```
Grafo encerra (__end__)
  ↓
Novas mensagens extraídas do final_state
  ↓
Adicionadas a st.session_state.chat_history
  ↓
st.rerun() → Interface atualizada
  ↓
Usuário vê resposta formatada com avatar
```

1.5 🗄️ Camada de Dados

1.5.1 Banco de Dados SQLite

Arquivo: `folha_pagamento.db`

Tabelas:

```sql
-- Tabela de Servidores
CREATE TABLE tb_servidores (
  id INTEGER PRIMARY KEY AUTOINCREMENT,
  nome TEXT NOT NULL,
  cpf TEXT,
  matricula TEXT UNIQUE NOT NULL,
  orgao TEXT,
  cargo TEXT
);

-- Tabela de Folha de Pagamento
CREATE TABLE tb_folha_pagamento (
  id INTEGER PRIMARY KEY AUTOINCREMENT,
  matricula TEXT NOT NULL,
  competencia TEXT,  -- Formato: YYYYMM (ex: 202401)
  vencimentos REAL,
  descontos REAL,
  liquido REAL,
  FOREIGN KEY (matricula) REFERENCES tb_servidores(matricula)
);
```

1.5.2 Fonte de Dados

CSV: `folha_pe_200linhas.csv`

Processamento:

```python
df = pd.read_csv("folha_pe_200linhas.csv")

# Servidores (sem duplicatas)
df_servidores = df[["nome","cpf","matricula","orgao","cargo"]].drop_duplicates()
df_servidores.to_sql("tb_servidores", conn, if_exists="append", index=False)

# Folha de Pagamento
df_folha = df[["matricula","competencia","vencimentos","descontos","liquido"]]
df_folha.to_sql("tb_folha_pagamento", conn, if_exists="append", index=False)
```

Arquivos Exportados: - `servidores.xlsx` / `servidores.csv` - `folha.xlsx` / `folha.csv`

1.6 🔗 Integrações Externas

1.6.1 LangChain

```python
# ChatGroq - Groq LLM
llm_groq = ChatGroq(
    model_name="llama-3.1-8b-instant",
    temperature=0.2,
    groq_api_key=groq_api_key
)

# ChatOpenAI - OpenAI LLM
llm_openai = ChatOpenAI(
    temperature=0.2,
    openai_api_key=openai_api_key,
    model_name="gpt-3.5-turbo"
```

```
)

# Tool Decorator
@tool
def query_folha_database(sql_query: str) -> str:
    """Docstring com descrição da ferramenta"""
    # Implementação
    pass

# Prompt Template
prompt = ChatPromptTemplate.from_messages([
    ("system", system_prompt),
    MessagesPlaceholder(variable_name="messages"),
])

# Binding Tools
agent_runnable = prompt | llm.bind_tools(tools)
```

1.6.2 LangGraph

```
# StateGraph com AgentState
workflow = StateGraph(AgentState)

# Adicionar nós
workflow.add_node("router", route_junction_node)
workflow.add_node("groq_agent", groq_agent_node)
workflow.add_node("openai_agent", openai_agent_node)
workflow.add_node("tools", ToolNode(tools))

# Arestas fixas
workflow.add_edge(START, "router")
workflow.add_edge("groq_agent", "router")
workflow.add_edge("openai_agent", "router")
workflow.add_edge("tools", "router")

# Arestas condicionais
workflow.add_conditional_edges(
    "router",
    router_logic,
    {
        "tools": "tools",
        "groq_agent": "groq_agent",
        "openai_agent": "openai_agent",
        "__end__": END
    }
)

# Compilar
app = workflow.compile()

# Invocar
result = app.invoke({"messages": [HumanMessage(content="...")]})
```

1.6.3 Streamlit Session State

```
# Inicialização
st.session_state.app = compila_grafo()
st.session_state.thread_id = "streamlit_thread_folha"
st.session_state.chat_history = [AIMessage(content="Olá!")]
st.session_state.processing_lock = False

# Processamento
```

```
with st.spinner("Consultando..."):
    current_state = {"messages": st.session_state.chat_history}
    final_state = st.session_state.app.invoke(current_state)
    new_messages = final_state["messages"][len(current_state["messages"]):]
    st.session_state.chat_history.extend(new_messages)
    st.rerun()
```

1.6.4 AgenticOps (Opcional)

```yaml
# config/agenticops_config.yaml
agenticops:
  enabled: true
  api_key: ${AGENTICOPS_API_KEY}

  tracking:
    track_events: true
    track_errors: true
    track_performance: true

  integrations:
    langchain:
      enabled: true
      track_llm_calls: true
    langgraph:
      enabled: true
      track_state_transitions: true
```

1.7 📋 Configuração CI/CD

1.7.1 GitHub Actions Pipeline

```
Push/PR → Trigger
    ↓
1. Validate (OBRIGATÓRIO)
    ├─ Specs validation
    ├─ Python 3.10/3.11/3.12
    └─ All checks must pass
    ↓
2. Code Quality
    ├─ Black formatting
    ├─ isort imports
    ├─ Flake8 linting
    └─ mypy typing
    ↓
3. Tests
    ├─ pytest execution
    ├─ Coverage report
    └─ Fail if < 70%
    ↓
4. Build
    ├─ Generate docs
    ├─ Create artifacts
    └─ Upload to storage
```

1.8 🔐 Segurança

1.8.1 Variáveis de Ambiente

```
.env (local)
├─ OPENAI_API_KEY
├─ GROQ_API_KEY
├─ AGENTICOPS_API_KEY
└─ DATABASE_PATH

GitHub Secrets (producção)
└─ Mesmo padrão acima
```

1.8.2 Validação de Input

```
User Input → Sanitize → Validate → Process
```

1.8.3 SQL Injection Prevention

```
├─ Use parameterized queries
├─ Validate SQL patterns
└─ Whitelist allowed operations
```

1.9 📈 Escalabilidade

1.9.1 Nível de Maturidade 1

Otimizações atuais: - Connection pooling SQLite - Message caching em memória - Batch processing de queries - Lazy loading de embeddings

Melhorias futuras: - PostgreSQL para escalabilidade - Redis para cache distributado - Kubernetes para orquestração - Load balancing

---

1.10 🔍 Monitoramento (AgenticOps)

1.10.1 Eventos Rastreados

```
├─ LLM calls (Groq, OpenAI)
├─ Tool executions
├─ State transitions
├─ Error occurrences
├─ Performance metrics
└─ Memory usage
```

1.10.2 Métricas Coletadas

```
├─ Latency (ms)
├─ Memory (MB)
├─ CPU (%)
├─ Error rate (%)
├─ Token usage
└─ Tool accuracy
```

1.11 📚 Referências de Padrões

1.11.1 Design Patterns Utilizados

1. **Agent Pattern**: Agentes especializados
2. **Strategy Pattern**: Diferentes LLMs
3. **Observer Pattern**: Event logging
4. **Singleton Pattern**: Database connection
5. **State Pattern**: State management

1.12 🚀 Performance

1.12.1 Otimizações

```
Query Cache         → Reduz DB calls em 70%
Message Batching    → Reduz API calls em 50%
Async Processing    → Melhora responsividade
Memory Management   → Reduz uso em 30%
```

Diagrama atualizado: 27/02/2026
Versão da Arquitetura: 1.0.0
Nível de Maturidade: 1